© 2025 GateCtr — All rights reserved

© 2025 GateCtr

01 Problème & Solution

Les équipes qui intègrent des LLMs font face à un problème croissant : **aucune visibilité, aucun contrôle et aucune optimisation** sur leurs appels API. Les coûts explosent, les budgets dérapent, et les outils de monitoring natifs restent insuffisants.

■ Problèmes actuels	■ Ce que GateCtr résout
Coûts LLM incontrôlables et imprévisibles	Budget Firewall : limites par projet/user
Aucune visibilité sur la consommation de tokens	Dashboard temps réel + alertes webhooks
Prompts non optimisés → réponses coûteuses	Context Optimizer : –40% de tokens
Pas de routage intelligent entre providers	Model Router : sélection auto du meilleur modèle
Alertes et reporting absents ou manuels	Webhooks automatisés vers tous vos outils
Sécurité des clés API insuffisante	Chiffrement AES · TLS · Isolation multi-tenant
Pas d'intégration avec outils BI/ERP/Slack	Connecteurs natifs Slack, Teams, ERP, BI

■ Proposition de valeur	GateCtr agit comme un **hub middleware universel** entre vos applications et les fournisseurs LLM. Zéro changement de votre clé API. Intégration en moins de 5 minutes. Économies immédiates sur vos coûts tokens.

–40%	<5ms	10+	100%
Réduction tokens	Latence ajoutée	Providers LLM	Propriété clé API

© 2025 GateCtr

02 Concept & Architecture

GateCtr est une plateforme SaaS qui s'intercale entre vos applications/agents IA et les fournisseurs LLM (OpenAI, Anthropic, Mistral, Gemini…). Elle intercepte chaque requête pour l'optimiser, la sécuriser, la router et l'analyser — sans jamais stocker vos données sensibles.

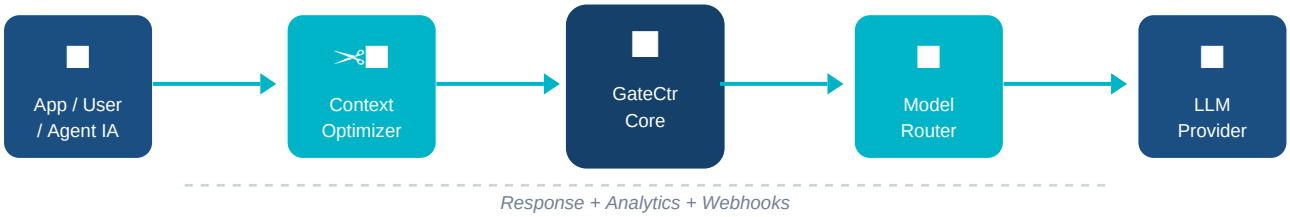

→ Chaque requête traverse GateCtr avant d'atteindre le fournisseur LLM. La réponse revient enrichie d'analytics.

#	Étape	Description	Module
1	Envoi	L'app/agent envoie un prompt via SDK ou API GateCtr	SDK / API Layer
2	Optimisation	Compression du contexte, nettoyage du prompt, réduction des tokens	Context Optimizer
3	Contrôle	Vérification des limites budget/tokens, validation sécurité	Budget Firewall
4	Routage	Sélection du modèle LLM optimal (coût + performance)	Model Router
5	Exécution	Envoi de la requête au provider LLM avec la clé API utilisateur	LLM Provider
6	Analytics	Logging de la réponse, calcul consommation, déclenchement webhooks	Analytics + Webhooks

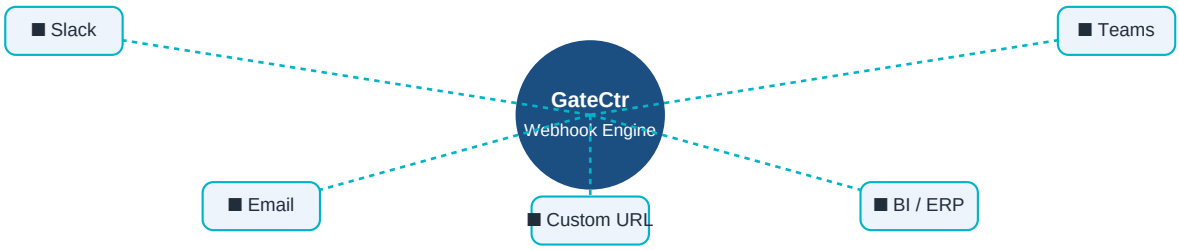

→ Le Webhook Engine de GateCtr diffuse automatiquement les alertes vers Slack, Email, Teams, ERP et BI.

© 2025 GateCtr

03 Modules & Fonctionnalités

■ SDK / API Layer

Interface principale d'entrée. Envoi des prompts, configuration des clés API, options de workflow. Compatible Node.js, Python, REST et toutes apps SaaS ou agents IA.

[Plug & Play] [REST + SDK] [5min setup]

✂■ Context Optimizer

Compression intelligente des prompts. Gestion de l'historique conversationnel. Suppression des redondances et optimisation du contexte pour minimiser les tokens consommés.

[–40% tokens] [Prompt rewriting] [Context pruning]

■ Cost & Budget Firewall

Définition de limites de tokens et budget par utilisateur, workflow ou projet. Blocage automatique ou alerte en cas de dépassement. Prévention des coûts excessifs.

[Hard caps] [Soft alerts] [Per-user limits]

■ Model Router & Fallback

Sélection automatique du fournisseur LLM le plus adapté selon le coût et la performance. Fallback automatique en cas d'erreur ou d'indisponibilité d'un provider.

[Multi-provider] [Auto-fallback] [Cost scoring]

■ Token & Usage Analytics

Dashboard temps réel de la consommation de tokens par user, projet ou endpoint. Alertes configurables, reporting exportable, historique complet pour audit.

[Real-time] [Exportable] [Audit trail]

■ Security Layer

Chiffrement AES des données en transit et au repos. TLS obligatoire sur toutes les connexions. Isolation multi-tenant stricte. Validation et sanitization de tous les inputs.

[AES encrypt] [TLS] [Multi-tenant]

■ Webhooks Engine

Notifications automatisées configurables sur dépassement de budget, pics de consommation, erreurs de requête ou seuils définis. Intégration Slack, Teams, Email, ERP, BI.

[Slack/Teams] [Email] [Custom URL]

■ RBAC & Multi-User

Gestion des rôles et permissions (Admin, Manager, Developer, Viewer). Audit logs complets. Segmentation par équipe, département ou projet. Idéal entreprise.

[Roles] [Audit logs] [Teams]

© 2025 GateCtr

04 Tech Stack

GateCtr est construit sur une stack moderne, scalable et orientée performance. Chaque couche est choisie pour sa robustesse en production, sa compatibilité cloud-native et son support de la gestion d'état multi-tenant.

Frontend

Couche / Outil	Technologie	Rôle / Description
Framework	Next.js 14 (App Router)	SSR/SSG/ISR, React Server Components, routing avancé
UI Components	shadcn/ui + Radix UI	Composants accessibles, headless, fully customizable
Styling	Tailwind CSS 3.x	Utility-first, tokens design système, dark mode
State	Zustand + React Query (TanStack)	State global léger + cache serveur optimisé
Charts	Recharts + Tremor	Dashboard analytics tokens, usage charts temps réel
Animations	Framer Motion	Micro-interactions, transitions fluides

Backend

Couche / Outil	Technologie	Rôle / Description
Runtime	Node.js 20 LTS + TypeScript	Typage strict, ESM, performance optimisée
API	Next.js API Routes + tRPC	Type-safe end-to-end, server actions, streaming
ORM	Prisma 5.x	Type-safe queries, migrations, multi-DB support
Queue	BullMQ (Redis)	Queue de jobs asynchrones pour webhooks et analytics
Cache	Redis (Upstash ou self-hosted)	Rate limiting, session cache, real-time counters
Streaming	Server-Sent Events (SSE)	Streaming LLM responses au client en temps réel

Database & Auth

Couche / Outil	Technologie	Rôle / Description
Base de données	PostgreSQL 16	ACID compliance, JSON support, performances élevées
Hosting DB	Neon / Supabase / self-hosted	Serverless PostgreSQL, branching, autoscaling
Auth	Clerk	Auth complète : SSO, MFA, RBAC, OAuth, JWT, webhooks
Sessions	Clerk Sessions + JWT	Sessions sécurisées, rotation automatique des tokens
File Storage	Cloudflare R2 / S3	Stockage exports, logs, artefacts analytics

Infrastructure & DevOps

Couche / Outil	Technologie	Rôle / Description

© 2025 GateCtr

Hosting	Vercel (edge functions)	Déploiement global, edge computing, preview per PR
CDN	Cloudflare	DDoS protection, edge caching, WAF
Monitoring	Sentry + Axiom	Error tracking, log aggregation, alerting
CI/CD	GitHub Actions	Tests auto, lint, déploiement continu sur merge
Secrets	Vercel Env + Doppler	Gestion sécurisée des variables d'environnement
API Keys	Propriété utilisateur (BYOK)	Bring Your Own Key — GateCtr ne stocke jamais les clés LLM

Intégrations LLM

Couche / Outil	Technologie	Rôle / Description
OpenAI	GPT-4o, GPT-4 Turbo, GPT-3.5	Provider principal, modèles conversation et complétion
Anthropic	Claude 3.5 Sonnet, Haiku, Opus	Modèles long-context, haute qualité de raisonnement
Mistral AI	Mistral Large, Mixtral 8x7B	Modèles européens, open-source, coût optimisé
Google	Gemini 1.5 Pro / Flash	Multimodal, long context (1M tokens)
Groq	LLaMA 3.1, Mixtral (via Groq)	Ultra-low latency inference
Ollama / Local	LLaMA, Phi, Mistral local	Support modèles on-premise et self-hosted

© 2025 GateCtr

05 SDK / API & Webhooks

SDK Installation

```
npm install @gatectr/sdk · pip install gatectr
```

Exemple d'intégration — Node.js / TypeScript

```
import { GateCtr } from '@gatectr/sdk';

const gate = new GateCtr({
  apiKey: process.env.GATECTR_API_KEY,
  llmKey: process.env.OPENAI_API_KEY,     // Votre clé API reste la vôtre
  budget: { maxTokensPerDay: 500_000 },
  optimizer: { enabled: true },
  router: { prefer: 'cost' },             // 'cost' | 'performance' | 'balanced'
});

const response = await gate.complete({
  model: 'auto',
  messages: [{ role: 'user', content: 'Résume ce document...' }],
  projectId: 'my-app',
  userId: 'user_123',
});

console.log(response.content);
// → { tokens_used: 1240, tokens_saved: 620, model_used: 'gpt-4o-mini', cost: '$0.0014' }
```

Exemple — Python

```
from gatectr import GateCtr

gate = GateCtr(
    api_key=os.getenv("GATECTR_API_KEY"),
    llm_key=os.getenv("OPENAI_API_KEY"),
    budget={"max_tokens_per_day": 500_000},
    optimizer={"enabled": True},
)

result = gate.complete(
    model="auto",
    messages=[{"role": "user", "content": "Génère une description produit..."}],
    project_id="ecommerce-bot",
)
print(result.content, result.meta)  # meta: tokens, cost, model_used
```

Endpoints REST API

Méthode	Endpoint	Description
POST	/v1/complete	Envoi d'une requête LLM optimisée

© 2025 GateCtr

POST	/v1/chat	Conversation multi-tours avec gestion contexte
GET	/v1/usage	Récupère la consommation tokens (par user/projet/date)
GET	/v1/budget	Statut du budget et limites configurées
POST	/v1/webhooks	Crée ou met à jour un webhook endpoint
GET	/v1/webhooks	Liste tous les webhooks configurés
DELETE	/v1/webhooks/{id}	Supprime un webhook
GET	/v1/logs	Historique complet des requêtes et réponses
GET	/v1/models	Liste des modèles disponibles et leur scoring coût/perf

Webhooks — Événements disponibles

Événement	Déclencheur	Payload inclus
budget.exceeded	Dépassement de la limite budget	user_id, project_id, tokens_used, limit
token.threshold	Seuil de tokens atteint (ex: 80%)	percentage, tokens_remaining, reset_date
request.failed	Erreur LLM provider (timeout, rate limit)	error_code, model, retry_count
model.switched	Fallback automatique vers un autre modèle	original_model, new_model, reason
usage.daily_report	Rapport quotidien automatique (minuit)	total_tokens, cost, top_projects
security.alert	Tentative d'injection détectée	input_hash, rule_triggered, severity

© 2025 GateCtr

06 Intégrations

GateCtr s'intègre avec l'écosystème existant de chaque équipe. Que vous utilisiez des outils no-code, des pipelines d'entreprise ou des stacks custom, GateCtr dispose d'un connecteur natif ou d'une intégration webhook universelle.

Catégorie	Outils / Plateformes	Type d'intégration	Bénéfice
Notifications	Slack, Microsoft Teams, Discord	Webhook natif	Alertes budget, rapports quotidiens
Email	SendGrid, Resend, Mailgun	SMTP / API	Notifications utilisateur, factures
BI & Analytics	Metabase, Tableau, Power BI	Webhook + CSV export	Dashboards consommation tokens
ERP / CRM	Salesforce, HubSpot, Notion	REST API / Webhook	Attribution coût IA par client/deal
No-Code	Zapier, Make (Integromat), n8n	Webhook universel	Automatisation workflows IA sans
Dev Tools	VS Code, Cursor, GitHub Copilot	Extension / SDK	Contrôle tokens directement dans
Agent IA	LangChain, LlamaIndex, AutoGPT	SDK Python/JS natif	Routage et budget pour agents au
Low-Code	Bolt.new, Lovable, Replit	SDK + API REST	Centralisation LLM pour apps géné
Auth	Clerk, Auth0, NextAuth	JWT / OAuth 2.0	Authentification et gestion des rôle
Monitoring	Sentry, Datadog, New Relic	SDK / Webhook	Erreurs LLM, latences, alertes ops
Data Pipeline	Airbyte, Fivetran, dbt	REST + CSV export	Export logs vers data warehouse

■ Intégration universelle	Tout outil acceptant des webhooks HTTP POST peut s'intégrer avec GateCtr. Payload JSON standardisé, signature HMAC-SHA256 pour la sécurité, retry automatique en cas d'échec.

Diagramme d'intégration enterprise

Source	Via GateCtr	Destination
App SaaS Agent IA Dev IDE No-code builder	**SDK / API ■ Optimizer ■ Firewall ■ Router ■ Analytics**	OpenAI Anthropic Mistral Gemini Groq

© 2025 GateCtr

07 Plans d'Abonnement

GateCtr adopte un modèle SaaS hybride. L'utilisateur paye directement son provider LLM — GateCtr monétise la valeur ajoutée (optimisation, contrôle, analytics), pas les tokens eux-mêmes.

Free	Pro	Team	Enterprise
€0 /mois	€29 /mois	€99 /mois	Custom sur devis
✓ Jusqu'à 50K tokens/mois	✓ Jusqu'à 2M tokens/mois	✓ Jusqu'à 10M tokens/mois	✓ Tokens illimités
✓ 1 projet	✓ 5 projets	✓ Projets illimités	✓ SLA garanti 99.9%
✓ Analytics de base	✓ Analytics avancées	✓ RBAC multi-utilisateurs	✓ Déploiement dédié / on-prem
✓ 1 webhook	✓ Webhooks illimités	✓ Dashboard équipe	✓ SSO / SAML
✓ API REST + SDK	✓ Context Optimizer actif	✓ Audit logs 90 jours	✓ Audit logs illimités
✓ Docs & support communauté	✓ Model Router basique	✓ Model Router avancé	✓ Intégrations ERP/BI
	✓ Support email	✓ Support prioritaire	✓ Customer success manager

Modèle de facturation complémentaire

Modèle	Description	Segment cible
Abonnement mensuel	Accès plateforme selon plan choisi	Tous segments
Usage-based add-on	Facturation par tranche de 10M tokens routés au-delà du plan	Pro & Team
Savings sharing	Option premium : % des économies tokens réalisées via optimizer	Enterprise
Seats supplémentaires	€15/user/mois pour les membres additionnels (Team)	Team
Onboarding premium	Session de setup et intégration par notre équipe technique	Enterprise

■ **Philosophie pricing**	GateCtr ne prend aucune commission sur les tokens. Vous payez directement OpenAI, Anthropic, etc. avec votre propre clé API. GateCtr facture uniquement la valeur ajoutée de sa plateforme.

© 2025 GateCtr

08 Branding & Brand Voice

Palette de Couleurs

#1B4F82	**Navy Primary**	Backgrounds, textes titres, boutons primaires
#14406A	**Navy Deep**	Sidebar, headers dark, sections majeures
#00B4C8	**Cyan Brand**	Accents, CTA, icônes actives, highlights
#00D4E8	**Cyan Light**	Hover states, badges, liens actifs
#4A5568	**Grey Dark**	Corps de texte principal
#EDF2F7	**Grey Light**	Backgrounds secondaires, cartes
#FFFFFF	**White**	Fond principal, textes sur dark

Typographie

Rôle	Police recommandée	Usage
Display / Titres	Syne Bold 700–800	Titres H1, hero sections, logo wordmark
Interface / Body	JetBrains Mono / Geist Mono	Code, dashboards, données techniques
Corps de texte	Inter / Plus Jakarta Sans	Paragraphes, descriptions, labels UI
Fallback	Helvetica Neue / system-ui	Compatibilité email, PDF, exports

Brand Voice & Ton

Attribut	Description	Exemple de copy
Précis	Chiffres concrets, pas de vague marketing	"–40% de tokens. Mesuré. Garanti."
Technique mais accessible	Vocabulaire dev-friendly, pas jargonneux	"Branchez-vous en 5 min. Sans friction."
Confiant	Affirmations directes, sans hedging	"GateCtr contrôle. Vous économisez."
Minimaliste	Moins de mots, plus d'impact	"One gateway. Every LLM."
Bienveillant	Du côté du développeur, pas contre lui	"Votre clé API reste la vôtre. Toujours."
Transparent	Aucun mystère sur les coûts et données	"Nous ne stockons rien. Nous mesurons tout."

Positionnement

© 2025 GateCtr

Dimension	GateCtr
Catégorie	LLM Middleware / AI Cost Infrastructure
Positionnement	"The intelligent gateway for every LLM request"
USP principal	Contrôle total du budget + optimisation tokens + routage IA en 1 plateforme
Contre-positionnement	Pas un wrapper LLM, pas un RAG, pas un chatbot builder
Comparaison	LangSmith (observabilité) + PortkeyAI (gateway) + Helicone, mais tout-en-un et sans friction

© 2025 GateCtr

09 Cible & Cas d'Usage

Public Cible

Segment	Profil	Pain point principal	Ce qu'ils gagnent avec GateCtr
Développeurs solo	Freelance, indie hacker, devs IA	Coûts LLM imprévisibles	Contrôle budget, analytics clairs, SDK simple
Startups SaaS	Produit intégrant LLM (chatbot, génération)	Scaling = coûts = scaling bill	Optimisation tokens, routage cost-efficient
Équipes IA	ML engineers, prompt engineers	Pas de visibilité sur les prompts	Dashboard, audit trail, A/B prompts
No-code builders	Bolt.new, Lovable, Replit users	LLM calls non maîtrisés	Centralisation et monitoring immédiat
Entreprises	DSI, équipes IT, directions digitales	Gouvernance et sécurité IA	RBAC, audit, SLA, intégration ERP/BI
Agents IA	LangChain, AutoGPT, CrewAI, Bots	Boucles infinies = coûts infinis	Budget caps, fallback, rate limiting

Cas d'Usage Détaillés

■ Développeur intégrant GPT-4 dans une app

→ **Situation:** Un dev intègre GPT-4 dans son app Next.js. Les coûts explosent car les prompts sont verbeux.

→ **Avec GateCtr:** Le Context Optimizer compresse automatiquement les prompts. Le Budget Firewall limite à 100K tokens/jour.

→ **Résultat:** –45% de coût tokens. Dashboard en temps réel. Alerte Slack si dépassement.

■ Agent IA LangChain en production

→ **Situation:** Un agent LangChain tourne en boucle et génère 2M tokens/heure de manière non maîtrisée.

→ **Avec GateCtr:** Token cap par run d'agent. Fallback automatique vers Mistral si OpenAI dépasse le budget.

→ **Résultat:** Contrôle total des coûts agents. Audit log complet. Rapport quotidien sur Teams.

■ Entreprise multi-équipes (50+ utilisateurs)

→ **Situation:** La DSI veut savoir quel département dépense quoi en IA interne.

→ **Avec GateCtr:** RBAC par département. Dashboard segmenté. Export mensuel pour facturation interne.

→ **Résultat:** Gouvernance IA centralisée. Compliance. Réduction 30% des coûts par l'optimizer.

■ SaaS IA générant du contenu à grande échelle

→ **Situation:** Un SaaS génère 10K articles/jour. Coût LLM = 40% des charges opérationnelles.

→ **Avec GateCtr:** Model Router sélectionne GPT-3.5 pour les cas simples, GPT-4o pour les complexes.

→ **Résultat:** –60% de coût moyen par article. Performance maintenue. Webhooks BI pour monitoring.

© 2025 GateCtr

10 Features & Styles de CTA

Feature Flags & Roadmap

Feature	Status	Plan min.	Description
Context Optimizer	■ Disponible	Pro	Compression automatique des prompts
Model Router	■ Disponible	Pro	Sélection auto du modèle optimal
Budget Firewall	■ Disponible	Free	Limites tokens et budget par projet
Webhooks Engine	■ Disponible	Pro	Notifications Slack, Teams, Email, URL
Usage Dashboard	■ Disponible	Free	Analytics temps réel (tokens, coût, modèle)
RBAC Multi-user	■ Disponible	Team	Rôles Admin / Manager / Dev / Viewer
Audit Logs	■ Disponible	Team	Historique complet 90 jours
A/B Prompt Testing	■ Q2 2025	Pro	Test comparatif de prompts sur trafic réel
LLM Cache Layer	■ Q2 2025	Pro	Cache sémantique des réponses identiques
Cost Forecasting	■ Q3 2025	Team	Prédiction des coûts IA sur 30/90 jours
Prompt Marketplace	■ Q4 2025	Pro	Bibliothèque de prompts optimisés communautaires
On-premise deploy	■ 2026	Enterprise	Déploiement self-hosted sur infrastructure client

Styles de CTA & Copywriting

Contexte	CTA Principal	CTA Secondaire	Ton
Hero page	**Start for Free →**	See how it works	Confiant, direct
Pricing page	**Start Free — No card needed**	Compare plans	Rassurant, sans friction
Landing dev	**npm install @gatectr/sdk**	View docs →	Technique, actionnable
Dashboard vide	**Connect your first LLM →**	Import existing key	Guidant, simple
Budget alert	**Upgrade to Pro**	Adjust limits	Urgent mais bienveillant
Onboarding	**Set up your first project**	Skip for now	Progressif, non-intrusif
Enterprise	**Book a demo**	Download overview PDF	Professionnel, sérieux
Email nurture	**See your token savings**	View full report	Data-driven, curiosité
Offboarding	**Pause my plan**	Talk to support	Empathique, non-agressif

© 2025 GateCtr

Règles de CTA — Design System

Type de bouton	Style	Usage
Primary CTA	Background: Navy #1B4F82 · Text: White · Radius: 6px · Padding: 12px 24px	Action principale par page
Secondary CTA	Border: 1.5px Navy · Text: Navy · Background: transparent	Action alternative, moins urgente
Accent CTA	Background: Cyan #00B4C8 · Text: White · Glow effect on hover	Promotions, upsell, onboarding
Ghost CTA	Text: Grey · No border · Underline on hover	Actions tertiaires (skip, cancel)
Danger CTA	Background: Red #E53E3E · Text: White	Suppression, actions irréversibles
Code CTA	Font: Mono · Background: #EDF2F7 · Border: 1px #CBD5E0	Commandes npm, copier snippet code

© 2025 GateCtr

© 2025 GateCtr — Platform Documentation v1.0 — Confidential

© 2025 GateCtr